

Travail Pratique - Analyse des Ventes d'un Magasin

Informations Générales

- Nom de l'étudiant:** Akpo Akisch
- Parcours:** Licence 3 Développement d'Application
- Université:** UCAO (Université Catholique d'Afrique de l'Ouest)
- UE:** Programmation Python
- Professeur:** Mr LOUKOUME
- Année académique:** 2024/2025
- Nombre de crédits:** 3

Objectif du TP

Ce travail pratique a pour objectif d'analyser les ventes d'un magasin à partir de données transactionnelles, en utilisant des outils de gestion de bases de données (SQLite) et de traitement des données (Pandas). Le TP consiste en la création de visualisations graphiques afin de mieux comprendre les tendances et comportements dans les ventes.

Résumé

Le TP comporte plusieurs étapes essentielles qui incluent :

- Collecte et préparation des données :** Extraction et nettoyage des données depuis une base SQLite.
- Analyse exploratoire :** Exploration des données avec Pandas, gestion des valeurs manquantes, et utilisation des jointures.
- Visualisation des données :** Création de graphiques pour visualiser l'évolution des ventes et la répartition des ventes par produit.
- Interprétation des résultats :** Interprétation des tendances, des pics et des éventuels creux dans les ventes.



Étape 1 : Modélisation de la Base de Données

Schéma Entité-Association (E/A)

Entités

Produits

- `id` : Identifiant unique du produit
- `nom` : Nom du produit
- `categorie_id` : Référence à la catégorie du produit
- `prix_unitaire` : Prix unitaire du produit

Categories

- `id` : Identifiant unique de la catégorie
- `nom` : Nom de la catégorie

Clients

- `id` : Identifiant unique du client
- `nom` : Nom du client
- `email` : Email du client
- `téléphone` : Numéro de téléphone du client

Ventes

- `id` : Identifiant unique de la vente
- `produit_id` : Référence au produit vendu
- `client_id` : Référence au client ayant effectué l'achat
- `employe_id` : Référence à l'employé qui a réalisé la vente
- `date` : Date de la vente
- `quantite` : Quantité de produit vendu
- `montant` : Montant total de la vente

Paielements

- `id` : Identifiant unique du paiement
- `vente_id` : Référence à la vente associée
- `mode_paiement` : Mode de paiement utilisé
- `statut` : Statut du paiement (par exemple, "complété", "en attente", etc.)
- `date_paiement` : Date du paiement

Employes

- `id` : Identifiant unique de l'employé
- `nom` : Nom de l'employé
- `poste` : Poste de l'employé dans l'entreprise
- `email` : Email de l'employé
- `téléphone` : Numéro de téléphone de l'employé

Relations

1. **Produits - Categories** : Un produit appartient à une catégorie.
2. **Ventes - Produits** : Une vente contient un produit spécifique.

3. **Ventes - Clients** : Une vente est effectuée par un client.
4. **Ventes - Employés** : Une vente est réalisée par un employé.
5. **Paielements - Ventes** : Un paiement est associé à une vente spécifique.

Conclusion

Ce modèle relationnel permet d'assurer l'intégrité des données et de faciliter l'analyse des ventes. La prochaine étape consistera à créer la base de données et insérer des données d'exemple.

Étape 2 : Création de la base de données et insertion des données simulées

2.1 Création des tables

Les tables ont été créées pour modéliser les catégories, produits, clients, employés, ventes et paiements. La structure de la base de données respecte le modèle fourni dans le document précédent.

```
In [1]: import sqlite3

conn = sqlite3.connect('ventes_magasin.db')
cursor = conn.cursor()

cursor.execute('''
CREATE TABLE IF NOT EXISTS Categories (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    nom TEXT NOT NULL UNIQUE
);
''')

cursor.execute('''
CREATE TABLE IF NOT EXISTS Produits (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    nom TEXT NOT NULL,
    categorie_id INTEGER,
    prix_unitaire REAL NOT NULL CHECK (prix_unitaire > 0),
    FOREIGN KEY (categorie_id) REFERENCES Categories (id) ON DELETE SET NULL
);
''')

cursor.execute('''
CREATE TABLE IF NOT EXISTS Clients (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    nom TEXT NOT NULL,
    email TEXT CHECK (email LIKE '%@%.%' OR email IS NULL),
    telephone TEXT
);
''')

cursor.execute('''
CREATE TABLE IF NOT EXISTS Employes (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    nom TEXT NOT NULL,
    poste TEXT NOT NULL,
```

```

        email TEXT CHECK (email LIKE '%@%.%' OR email IS NULL),
        telephone TEXT
    );
'''

cursor.execute('''
CREATE TABLE IF NOT EXISTS Ventes (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    produit_id INTEGER NOT NULL,
    client_id INTEGER NOT NULL,
    employe_id INTEGER,
    date TEXT NOT NULL CHECK (date LIKE '____-__-__'),
    quantite INTEGER NOT NULL CHECK (quantite > 0),
    montant REAL NOT NULL CHECK (montant >= 0),
    FOREIGN KEY (produit_id) REFERENCES Produits (id) ON DELETE RESTRICT,
    FOREIGN KEY (client_id) REFERENCES Clients (id) ON DELETE RESTRICT,
    FOREIGN KEY (employe_id) REFERENCES Employes (id) ON DELETE SET NULL
);
''')

cursor.execute('''
CREATE TABLE IF NOT EXISTS Paiements (
    id INTEGER PRIMARY KEY AUTOINCREMENT,
    vente_id INTEGER NOT NULL,
    mode_paiement TEXT NOT NULL CHECK (mode_paiement IN ('Carte', 'Espèces', 'Virement')),
    statut TEXT NOT NULL CHECK (statut IN ('Complété', 'En attente', 'Échoué')),
    date_paiement TEXT CHECK (date_paiement LIKE '____-__-__' OR date_paiement IS NULL),
    FOREIGN KEY (vente_id) REFERENCES Ventes (id) ON DELETE CASCADE
);
''')

conn.commit()
conn.close()

```

2.2 Insertion de données

Nous avons inséré les données suivantes dans la base de données :

- **Catégories** : 5 catégories de produits.
- **Produits** : 7 produits distincts.
- **Clients** : 10 clients différents générés à l'aide de Faker.
- **Employés** : 5 employés générés à l'aide de Faker.
- **Ventes** : 100 ventes simulées générées aléatoirement avec des produits, des clients et des employés sur 6 mois.
- **Paiements** : 100 paiements associés aux ventes, avec des modes de paiement aléatoires et des statuts (Payé ou Non Payé).

Détails des ventes :

Les ventes ont été générées aléatoirement, avec des dates récentes (dans le mois écoulé). Chaque vente a une quantité aléatoire et un montant total calculé en fonction du produit et de la quantité vendue.

```

In [2]: import sqlite3
import random
from faker import Faker

```

```

from datetime import datetime, timedelta

fake = Faker('fr_FR') # Version française pour des données réalistes

def generer_donnees():
    conn = sqlite3.connect('ventes_magasin.db')
    cursor = conn.cursor()

    categories = ['Électronique', 'Vêtements', 'Meubles', 'Jouets', 'Alimentation']
    cursor.executemany("INSERT INTO Categories (nom) VALUES (?)", [(c,) for c in categories])

    produits = [
        ('Telephone', 1, 79900.99),
        ('Ordinateur portable', 1, 129900.99),
        ('Habit', 2, 1900.99),
        ('Pantalon', 2, 4900.99),
        ('Tableau', 3, 59900.99),
        ('Monopoli', 4, 1400.99),
        ('Chocolat', 5, 400.99)
    ]
    cursor.executemany("INSERT INTO Produits (nom, categorie_id, prix_unitaire) VALUES (?, ?, ?)", produits)

    clients = [(fake.name(), fake.email(), fake.phone_number()) for _ in range(10)]
    cursor.executemany("INSERT INTO Clients (nom, email, telephone) VALUES (?, ?, ?)", clients)

    postes = ['Vendeur', 'Valideur', 'Caissier', 'Responsable', 'Gérant']
    employes = [(fake.name(), postes[i], f"employe{i}@magasin.com", fake.phone_number()) for i in range(5)]
    cursor.executemany("INSERT INTO Employes (nom, poste, email, telephone) VALUES (?, ?, ?, ?)", employes)

    # Ventes (100 ventes sur 6 mois)
    start_date = datetime.now() - timedelta(days=180)
    for _ in range(100):
        produit_id = random.randint(1, len(produits))
        client_id = random.randint(1, 10)
        employe_id = random.randint(1, 5)
        quantite = random.randint(1, 5)

        cursor.execute("SELECT prix_unitaire FROM Produits WHERE id = ?", (produit_id,))
        prix_unitaire = cursor.fetchone()[0]
        montant = round(quantite * prix_unitaire, 2)

        # Date aléatoire sur 6 mois
        jours_aleatoires = random.randint(0, 180)
        date_vente = (start_date + timedelta(days=jours_aleatoires)).strftime('%Y-%m-%d')

        cursor.execute("""
            INSERT INTO Ventes (produit_id, client_id, employe_id, date, quantite, montant)
            VALUES (?, ?, ?, ?, ?, ?)
            """, (produit_id, client_id, employe_id, date_vente, quantite, montant))

    #génération des paiements
    modes_paiement = ['Carte', 'Espèces', 'Virement']
    statuts_possibles = ['Complété', 'En attente', 'Échoué']

    for vente_id in range(1, 101):
        mode = random.choice(modes_paiement)
        statut = random.choices(statuts_possibles, weights=[0.8, 0.15, 0.05])[0] # 80% Complété

        cursor.execute("SELECT date FROM Ventes WHERE id = ?", (vente_id,))
        date_vente = datetime.strptime(cursor.fetchone()[0], '%Y-%m-%d')

```

```

# Ajout cohérent de la date de paiement
if statut == 'Complété':
    jours_retard = random.randint(0, 3)
else:
    jours_retard = random.randint(1, 7) # Retard plus long si non complété

date_paiement = (date_vente + timedelta(days=jours_retard)).strftime('%Y-%m-%d')

cursor.execute("""
    INSERT INTO Paiements (vente_id, mode_paiement, statut, date_paiement)
    VALUES (?, ?, ?, ?)
""", (vente_id, mode, statut, date_paiement))

conn.commit()
conn.close()
print("Données générées avec succès!")

if __name__ == '__main__':
    generer_donnees()

```

Données générées avec succès!

2.3 Vérification des données

Une fois les données insérées, des requêtes ont été effectuées pour vérifier l'intégrité des informations dans chaque table de la base de données.

```

In [3]: import sqlite3

conn = sqlite3.connect('ventes_magasin.db')
cursor = conn.cursor()

# Vérification des données

cursor.execute('SELECT * FROM Categories;')
print("\n=== CATÉGORIES ===")
print("(ID, Nom)")
for row in cursor.fetchall():
    print(row)

cursor.execute('SELECT * FROM Produits;')
print("\n=== PRODUITS ===")
print("(ID, Nom, Catégorie_ID, Prix)")
for row in cursor.fetchall():
    print(row)

cursor.execute('SELECT * FROM Clients;')
print("\n=== CLIENTS ===")
print("(ID, Nom, Email, Téléphone)")
for row in cursor.fetchall():
    print(row)

cursor.execute('SELECT * FROM Employes;')
print("\n=== EMPLOYÉS ===")
print("(ID, Nom, Poste, Email, Téléphone)")
for row in cursor.fetchall():
    print(row)

```

```
cursor.execute('SELECT * FROM Ventes;')
print("\n=== VENTES ===")
print("(ID, Produit_ID, Client_ID, Employé_ID, Date, Quantité, Montant)")
for row in cursor.fetchall():
    print(row)

cursor.execute('SELECT * FROM Paiements;')
print("\n=== PAIEMENTS ===")
print("(ID, Vente_ID, Mode, Statut, Date_Paiement)")
for row in cursor.fetchall():
    print(row)

conn.close()
print("\nVérification terminée!")
```

=== CATÉGORIES ===

(ID, Nom)
(1, 'Électronique')
(2, 'Vêtements')
(3, 'Meubles')
(4, 'Jouets')
(5, 'Alimentation')

=== PRODUITS ===

(ID, Nom, Catégorie_ID, Prix)
(1, 'Telephone', 1, 79900.99)
(2, 'Ordinateur portable', 1, 129900.99)
(3, 'Habit', 2, 1900.99)
(4, 'Pantalon', 2, 4900.99)
(5, 'Tableau', 3, 59900.99)
(6, 'Monopoli', 4, 1400.99)
(7, 'Chocolat', 5, 400.99)

=== CLIENTS ===

(ID, Nom, Email, Téléphone)
(1, 'Théodore de la Joseph', 'letellierdominique@example.org', '+33 (0)3 55 66 78 94')
(2, 'Élise-Michelle Adam', 'jschmitt@example.org', '+33 (0)6 32 20 06 20')
(3, 'Virginie Lucas', 'aurore75@example.org', '+33 (0)2 28 60 50 89')
(4, 'Sylvie Guillaume', 'nicolasstephanie@example.com', '01 56 17 16 10')
(5, 'Alix Legrand', 'augeranne@example.net', '02 31 92 17 44')
(6, 'Olivie-Anaïs Normand', 'blancalexandre@example.net', '0586471651')
(7, 'Noël Maillet', 'pichonhelene@example.org', '+33 5 96 48 58 69')
(8, 'Emmanuelle-Dominique Gaudin', 'astridbarre@example.net', '0477536581')
(9, 'Jérôme Muller', 'penelopelefevre@example.com', '01 48 96 05 82')
(10, 'Henriette Laine', 'helenemartins@example.net', '+33 4 57 97 13 88')

=== EMPLOYÉS ===

(ID, Nom, Poste, Email, Téléphone)
(1, 'Marcel Tessier', 'Vendeur', 'employe0@magasin.com', '0471060989')
(2, 'Philippine Joseph', 'Valideur', 'employe1@magasin.com', '0388389484')
(3, 'Éric Pierre', 'Caissier', 'employe2@magasin.com', '+33 (0)4 93 96 83 34')
(4, 'Monique Delmas de la Bouvier', 'Responsable', 'employe3@magasin.com', '+33 4 85 00 61 59')
(5, 'Charles-Auguste Courtois', 'Gérant', 'employe4@magasin.com', '0143923165')

=== VENTES ===

(ID, Produit_ID, Client_ID, Employé_ID, Date, Quantité, Montant)
(1, 4, 3, 3, '2024-11-24', 5, 24504.95)
(2, 2, 10, 3, '2025-01-24', 3, 389702.97)
(3, 1, 8, 3, '2024-12-19', 2, 159801.98)
(4, 1, 5, 5, '2024-12-09', 3, 239702.97)
(5, 1, 8, 4, '2025-01-11', 3, 239702.97)
(6, 4, 1, 5, '2024-10-12', 4, 19603.96)
(7, 3, 1, 5, '2025-02-01', 4, 7603.96)
(8, 4, 10, 3, '2024-10-30', 1, 4900.99)
(9, 5, 4, 4, '2024-12-24', 2, 119801.98)
(10, 1, 1, 1, '2024-11-16', 2, 159801.98)
(11, 5, 6, 2, '2024-11-18', 1, 59900.99)
(12, 6, 1, 4, '2025-03-04', 5, 7004.95)
(13, 6, 3, 4, '2025-01-29', 3, 4202.97)
(14, 4, 6, 3, '2024-11-03', 2, 9801.98)
(15, 2, 9, 2, '2024-12-26', 1, 129900.99)
(16, 1, 4, 5, '2025-02-07', 3, 239702.97)
(17, 3, 7, 3, '2025-02-28', 5, 9504.95)
(18, 7, 10, 5, '2024-10-24', 5, 2004.95)

(19, 6, 9, 3, '2024-11-09', 2, 2801.98)
(20, 1, 9, 4, '2024-12-28', 1, 79900.99)
(21, 1, 5, 5, '2025-03-01', 3, 239702.97)
(22, 1, 3, 5, '2025-01-04', 2, 159801.98)
(23, 3, 3, 3, '2025-03-13', 1, 1900.99)
(24, 3, 4, 5, '2025-01-15', 2, 3801.98)
(25, 7, 1, 2, '2024-10-06', 2, 801.98)
(26, 1, 2, 1, '2024-12-12', 3, 239702.97)
(27, 4, 8, 1, '2024-12-08', 5, 24504.95)
(28, 3, 4, 3, '2024-11-07', 1, 1900.99)
(29, 5, 9, 1, '2025-03-18', 1, 59900.99)
(30, 4, 5, 2, '2025-02-03', 4, 19603.96)
(31, 1, 4, 4, '2025-01-06', 4, 319603.96)
(32, 2, 2, 4, '2024-12-31', 5, 649504.95)
(33, 6, 8, 2, '2025-03-11', 3, 4202.97)
(34, 1, 8, 3, '2025-03-05', 2, 159801.98)
(35, 7, 8, 2, '2024-11-10', 5, 2004.95)
(36, 2, 2, 2, '2025-01-28', 5, 649504.95)
(37, 4, 9, 3, '2024-10-12', 2, 9801.98)
(38, 4, 4, 4, '2024-10-19', 5, 24504.95)
(39, 1, 5, 1, '2024-11-09', 4, 319603.96)
(40, 2, 4, 5, '2024-10-30', 2, 259801.98)
(41, 7, 5, 4, '2024-12-08', 1, 400.99)
(42, 4, 4, 3, '2024-12-30', 1, 4900.99)
(43, 2, 9, 4, '2024-10-28', 4, 519603.96)
(44, 6, 2, 5, '2025-02-14', 1, 1400.99)
(45, 3, 9, 3, '2025-02-05', 1, 1900.99)
(46, 1, 7, 5, '2024-12-31', 3, 239702.97)
(47, 7, 3, 1, '2025-02-07', 3, 1202.97)
(48, 7, 10, 5, '2024-11-28', 1, 400.99)
(49, 1, 1, 3, '2025-01-29', 3, 239702.97)
(50, 7, 9, 4, '2024-12-12', 3, 1202.97)
(51, 1, 9, 1, '2025-02-03', 3, 239702.97)
(52, 1, 6, 1, '2025-03-04', 4, 319603.96)
(53, 4, 10, 3, '2025-02-07', 1, 4900.99)
(54, 3, 5, 1, '2024-12-22', 3, 5702.97)
(55, 1, 6, 4, '2024-12-08', 2, 159801.98)
(56, 2, 2, 1, '2024-10-28', 3, 389702.97)
(57, 7, 6, 4, '2024-11-06', 3, 1202.97)
(58, 4, 4, 3, '2025-03-17', 1, 4900.99)
(59, 6, 10, 3, '2024-10-13', 2, 2801.98)
(60, 7, 5, 1, '2025-03-15', 1, 400.99)
(61, 6, 2, 3, '2025-02-01', 3, 4202.97)
(62, 4, 4, 3, '2024-10-28', 4, 19603.96)
(63, 7, 4, 5, '2024-11-13', 2, 801.98)
(64, 7, 10, 5, '2025-01-11', 4, 1603.96)
(65, 4, 6, 2, '2025-01-19', 1, 4900.99)
(66, 5, 10, 4, '2024-12-25', 1, 59900.99)
(67, 3, 4, 1, '2025-02-11', 3, 5702.97)
(68, 3, 7, 1, '2024-10-30', 2, 3801.98)
(69, 4, 10, 4, '2024-11-22', 3, 14702.97)
(70, 2, 4, 2, '2025-04-04', 1, 129900.99)
(71, 5, 3, 5, '2024-11-22', 5, 299504.95)
(72, 7, 8, 3, '2024-11-29', 3, 1202.97)
(73, 3, 10, 4, '2024-10-25', 3, 5702.97)
(74, 5, 10, 3, '2024-11-27', 4, 239603.96)
(75, 3, 5, 4, '2024-12-29', 2, 3801.98)
(76, 3, 1, 5, '2024-10-11', 2, 3801.98)
(77, 6, 6, 2, '2024-10-12', 2, 2801.98)
(78, 2, 2, 5, '2025-01-18', 2, 259801.98)

(79, 2, 5, 4, '2024-11-19', 3, 389702.97)
 (80, 7, 3, 5, '2025-03-21', 4, 1603.96)
 (81, 6, 2, 1, '2024-12-29', 4, 5603.96)
 (82, 6, 2, 4, '2025-03-04', 1, 1400.99)
 (83, 5, 8, 2, '2024-10-22', 4, 239603.96)
 (84, 6, 9, 3, '2025-04-04', 4, 5603.96)
 (85, 6, 10, 2, '2024-12-29', 4, 5603.96)
 (86, 5, 3, 2, '2024-11-19', 5, 299504.95)
 (87, 3, 2, 3, '2025-02-08', 5, 9504.95)
 (88, 1, 4, 4, '2024-12-22', 5, 399504.95)
 (89, 6, 2, 2, '2024-11-23', 5, 7004.95)
 (90, 4, 1, 1, '2024-10-10', 2, 9801.98)
 (91, 4, 6, 4, '2025-01-29', 5, 24504.95)
 (92, 1, 7, 4, '2024-10-16', 1, 79900.99)
 (93, 6, 10, 4, '2025-02-07', 1, 1400.99)
 (94, 2, 1, 4, '2025-01-11', 2, 259801.98)
 (95, 6, 3, 1, '2024-11-06', 5, 7004.95)
 (96, 2, 7, 3, '2024-11-12', 3, 389702.97)
 (97, 1, 5, 4, '2025-02-23', 1, 79900.99)
 (98, 4, 6, 3, '2024-10-16', 3, 14702.97)
 (99, 5, 1, 4, '2025-02-08', 4, 239603.96)
 (100, 5, 2, 4, '2025-01-23', 1, 59900.99)

=== PAIEMENTS ===

(ID, Vente_ID, Mode, Statut, Date_Paiement)
 (1, 1, 'Virement', 'Complété', '2024-11-26')
 (2, 2, 'Espèces', 'Complété', '2025-01-24')
 (3, 3, 'Carte', 'Complété', '2024-12-21')
 (4, 4, 'Carte', 'En attente', '2024-12-14')
 (5, 5, 'Virement', 'Complété', '2025-01-12')
 (6, 6, 'Espèces', 'En attente', '2024-10-18')
 (7, 7, 'Carte', 'Complété', '2025-02-02')
 (8, 8, 'Carte', 'Complété', '2024-10-30')
 (9, 9, 'Carte', 'Complété', '2024-12-27')
 (10, 10, 'Virement', 'Complété', '2024-11-18')
 (11, 11, 'Carte', 'Complété', '2024-11-18')
 (12, 12, 'Espèces', 'Complété', '2025-03-07')
 (13, 13, 'Carte', 'En attente', '2025-02-04')
 (14, 14, 'Carte', 'Complété', '2024-11-05')
 (15, 15, 'Espèces', 'Complété', '2024-12-26')
 (16, 16, 'Carte', 'Complété', '2025-02-08')
 (17, 17, 'Carte', 'En attente', '2025-03-01')
 (18, 18, 'Carte', 'Complété', '2024-10-25')
 (19, 19, 'Carte', 'Complété', '2024-11-11')
 (20, 20, 'Espèces', 'Complété', '2024-12-28')
 (21, 21, 'Virement', 'Échoué', '2025-03-08')
 (22, 22, 'Espèces', 'En attente', '2025-01-07')
 (23, 23, 'Espèces', 'Complété', '2025-03-16')
 (24, 24, 'Carte', 'Complété', '2025-01-15')
 (25, 25, 'Virement', 'Complété', '2024-10-08')
 (26, 26, 'Espèces', 'Complété', '2024-12-14')
 (27, 27, 'Virement', 'Complété', '2024-12-09')
 (28, 28, 'Espèces', 'Complété', '2024-11-07')
 (29, 29, 'Espèces', 'Complété', '2025-03-21')
 (30, 30, 'Espèces', 'Complété', '2025-02-06')
 (31, 31, 'Carte', 'Complété', '2025-01-09')
 (32, 32, 'Espèces', 'Complété', '2024-12-31')
 (33, 33, 'Virement', 'Complété', '2025-03-12')
 (34, 34, 'Virement', 'Complété', '2025-03-08')
 (35, 35, 'Carte', 'Complété', '2024-11-10')

(36, 36, 'Virement', 'Complété', '2025-01-28')
(37, 37, 'Espèces', 'Complété', '2024-10-13')
(38, 38, 'Carte', 'Complété', '2024-10-21')
(39, 39, 'Espèces', 'Complété', '2024-11-10')
(40, 40, 'Espèces', 'Complété', '2024-11-02')
(41, 41, 'Espèces', 'Complété', '2024-12-10')
(42, 42, 'Virement', 'Complété', '2024-12-31')
(43, 43, 'Espèces', 'Complété', '2024-10-31')
(44, 44, 'Carte', 'Complété', '2025-02-17')
(45, 45, 'Espèces', 'Complété', '2025-02-06')
(46, 46, 'Carte', 'Complété', '2024-12-31')
(47, 47, 'Carte', 'Complété', '2025-02-09')
(48, 48, 'Virement', 'Complété', '2024-11-28')
(49, 49, 'Espèces', 'Complété', '2025-01-29')
(50, 50, 'Espèces', 'Complété', '2024-12-15')
(51, 51, 'Espèces', 'Complété', '2025-02-06')
(52, 52, 'Virement', 'Complété', '2025-03-06')
(53, 53, 'Espèces', 'Complété', '2025-02-10')
(54, 54, 'Virement', 'Complété', '2024-12-24')
(55, 55, 'Virement', 'Complété', '2024-12-08')
(56, 56, 'Espèces', 'Complété', '2024-10-29')
(57, 57, 'Espèces', 'Complété', '2024-11-09')
(58, 58, 'Espèces', 'Complété', '2025-03-19')
(59, 59, 'Espèces', 'Complété', '2024-10-15')
(60, 60, 'Carte', 'Complété', '2025-03-17')
(61, 61, 'Carte', 'Complété', '2025-02-04')
(62, 62, 'Virement', 'Complété', '2024-10-30')
(63, 63, 'Espèces', 'Complété', '2024-11-14')
(64, 64, 'Carte', 'Complété', '2025-01-13')
(65, 65, 'Espèces', 'Complété', '2025-01-21')
(66, 66, 'Virement', 'Échoué', '2024-12-27')
(67, 67, 'Virement', 'Complété', '2025-02-11')
(68, 68, 'Carte', 'Complété', '2024-11-01')
(69, 69, 'Carte', 'Complété', '2024-11-22')
(70, 70, 'Virement', 'Complété', '2025-04-07')
(71, 71, 'Espèces', 'Complété', '2024-11-24')
(72, 72, 'Carte', 'Complété', '2024-11-29')
(73, 73, 'Virement', 'En attente', '2024-11-01')
(74, 74, 'Espèces', 'Complété', '2024-11-30')
(75, 75, 'Virement', 'Complété', '2025-01-01')
(76, 76, 'Carte', 'Échoué', '2024-10-18')
(77, 77, 'Espèces', 'Complété', '2024-10-13')
(78, 78, 'Carte', 'Complété', '2025-01-21')
(79, 79, 'Carte', 'Complété', '2024-11-20')
(80, 80, 'Virement', 'Échoué', '2025-03-22')
(81, 81, 'Carte', 'Complété', '2024-12-30')
(82, 82, 'Carte', 'Complété', '2025-03-06')
(83, 83, 'Carte', 'Complété', '2024-10-24')
(84, 84, 'Carte', 'Complété', '2025-04-05')
(85, 85, 'Virement', 'Complété', '2024-12-31')
(86, 86, 'Carte', 'En attente', '2024-11-23')
(87, 87, 'Virement', 'En attente', '2025-02-14')
(88, 88, 'Virement', 'En attente', '2024-12-29')
(89, 89, 'Espèces', 'Complété', '2024-11-25')
(90, 90, 'Virement', 'Complété', '2024-10-12')
(91, 91, 'Espèces', 'Complété', '2025-01-30')
(92, 92, 'Virement', 'Complété', '2024-10-17')
(93, 93, 'Carte', 'En attente', '2025-02-10')
(94, 94, 'Espèces', 'Complété', '2025-01-12')
(95, 95, 'Espèces', 'Complété', '2024-11-09')

```
(96, 96, 'Virement', 'Échoué', '2024-11-16')
(97, 97, 'Espèces', 'Complété', '2025-02-24')
(98, 98, 'Carte', 'Complété', '2024-10-19')
(99, 99, 'Virement', 'Complété', '2025-02-08')
(100, 100, 'Espèces', 'Complété', '2025-01-25')
```

Vérification terminée!

Étape 3 : Extraction des données avec Python (avec Pandas)

Objectif

L'objectif de cette étape est de charger les données de la base SQLite dans Python en utilisant **Pandas** et de les manipuler facilement dans des DataFrames pour les étapes suivantes du projet.

1. Connexion à la base de données SQLite

Nous nous connectons à la base de données `ventes_magasin.db` en utilisant le module `sqlite3` de Python.

```
In [4]: import sqlite3
import pandas as pd

conn = sqlite3.connect('ventes_magasin.db')
```

2. Extraction des données avec Pandas

Nous chargeons les données des tables dans des DataFrames Pandas à l'aide de `pd.read_sql_query()`.

```
In [5]: categories_df = pd.read_sql_query("SELECT * FROM Categories;", conn)
produits_df = pd.read_sql_query("SELECT * FROM Produits;", conn)
clients_df = pd.read_sql_query("SELECT * FROM Clients;", conn)
employes_df = pd.read_sql_query("SELECT * FROM Employes;", conn)
ventes_df = pd.read_sql_query("SELECT * FROM Ventes;", conn)
paiements_df = pd.read_sql_query("SELECT * FROM Paiements;", conn)
```

3. Jointure des tables pour obtenir des informations utiles

Nous joignons les tables Ventes, Produits, et Clients pour obtenir un tableau combiné avec les informations sur chaque vente ('produit', 'client', 'date', 'quantité', 'montant').

```
In [6]: # Jointure entre les ventes avec les produits et les clients
ventes_clients_produits_df = pd.read_sql_query("""
    SELECT V.id AS vente_id,
           P.nom AS produit,
           C.nom AS client,
           V.date AS date_vente,
           V.quantite,
           V.montant
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Clients C ON V.client_id = C.id;
```

```

""" , conn)
#Jointure entre Les ventes et Les employés
ventes_employes_df = pd.read_sql_query("""
    SELECT V.id AS vente_id,
           P.nom AS produit,
           C.nom AS client,
           E.nom AS employe,
           V.date AS date_vente,
           V.quantite,
           V.montant
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Clients C ON V.client_id = C.id
    JOIN Employes E ON V.employe_id = E.id;
""", conn)

#Jointure entre Les ventes et Les paiements
ventes_paiements_df = pd.read_sql_query("""
    SELECT V.id AS vente_id,
           P.nom AS produit,
           C.nom AS client,
           V.date AS date_vente,
           V.quantite,
           V.montant,
           Pa.mode_paiement,
           Pa.statut,
           Pa.date_paiement
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Clients C ON V.client_id = C.id
    JOIN Paiements Pa ON V.id = Pa.vente_id;
""", conn)

# Jointure entre Les ventes et Les catégories de produits
ventes_categories_df = pd.read_sql_query("""
    SELECT V.id AS vente_id,
           P.nom AS produit,
           C.nom AS client,
           V.date AS date_vente,
           V.quantite,
           V.montant,
           Ca.nom AS categorie
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Clients C ON V.client_id = C.id
    JOIN Categories Ca ON P.categorie_id = Ca.id;
""", conn)

# Jointure entre toutes Les tables pour obtenir une vue complète
ventes_completes_df = pd.read_sql_query("""
    SELECT V.id AS vente_id,
           P.nom AS produit,
           C.nom AS client,
           V.date AS date_vente,
           V.quantite,
           V.montant,
           E.nom AS employe,
           Pa.mode_paiement, -- Mode de paiement
           Pa.statut,        -- Statut du paiement
           Cat.nom AS categorie
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Clients C ON V.client_id = C.id

```

```

        JOIN Employes E ON V.employe_id = E.id
        JOIN Paiements Pa ON V.id = Pa.vente_id
        JOIN Categories Cat ON P.categorie_id = Cat.id;
""" , conn)
ventes_jointures = pd.read_sql_query("""
    SELECT
        V.id AS vente_id,
        V.date AS date_vente,
        P.nom AS produit,
        P.prix_unitaire,
        V.quantite,
        V.montant,
        C.nom AS client,
        E.nom AS employe,
        Pa.mode_paiement,
        Pa.statut,
        Pa.date_paiement,
        Cat.nom AS categorie
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Clients C ON V.client_id = C.id
    LEFT JOIN Employes E ON V.employe_id = E.id
    LEFT JOIN Paiements Pa ON V.id = Pa.vente_id
    JOIN Categories Cat ON P.categorie_id = Cat.id
""", conn)

```

4. Vérification des données extraites

Nous affichons les 5 premières lignes de chaque DataFrame pour vérifier que les données ont été correctement extraites. La méthode `head()` de Pandas permet d'afficher un échantillon des données et de confirmer qu'elles sont bien importées.

```

In [7]: print("=== TABLES DE BASE ===")
print("\nCatégories :\n", categories_df.head())
print("\nProduits :\n", produits_df.head())
print("\nClients :\n", clients_df.head())
print("\nEmployés :\n", employes_df.head())
print("\nVentes :\n", ventes_df.head())
print("\nPaiements :\n", paiements_df.head())

```

=== TABLES DE BASE ===

Catégories :

	id	nom
0	1	Électronique
1	2	Vêtements
2	3	Meubles
3	4	Jouets
4	5	Alimentation

Produits :

	id	nom	categorie_id	prix_unitaire
0	1	Telephone	1	79900.99
1	2	Ordinateur portable	1	129900.99
2	3	Habit	2	1900.99
3	4	Pantalon	2	4900.99
4	5	Tableau	3	59900.99

Clients :

	id	nom	email \
0	1	Théodore de la Joseph	letellierdominique@example.org
1	2	Élise-Michelle Adam	jschmitt@example.org
2	3	Virginie Lucas	aurore75@example.org
3	4	Sylvie Guillaume	nicolasstephanie@example.com
4	5	Alix Legrand	augeranne@example.net

	telephone
0	+33 (0)3 55 66 78 94
1	+33 (0)6 32 20 06 20
2	+33 (0)2 28 60 50 89
3	01 56 17 16 10
4	02 31 92 17 44

Employés :

	id	nom	poste	email \
0	1	Marcel Tessier	Vendeur	employe0@magasin.com
1	2	Philippine Joseph	Valideur	employe1@magasin.com
2	3	Éric Pierre	Caissier	employe2@magasin.com
3	4	Monique Delmas de la Bouvier	Responsable	employe3@magasin.com
4	5	Charles-Auguste Courtois	Gérant	employe4@magasin.com

	telephone
0	0471060989
1	0388389484
2	+33 (0)4 93 96 83 34
3	+33 4 85 00 61 59
4	0143923165

Ventes :

	id	produit_id	client_id	employe_id	date	quantite	montant
0	1	4	3	3	2024-11-24	5	24504.95
1	2	2	10	3	2025-01-24	3	389702.97
2	3	1	8	3	2024-12-19	2	159801.98
3	4	1	5	5	2024-12-09	3	239702.97
4	5	1	8	4	2025-01-11	3	239702.97

Paielements :

	id	vente_id	mode_paiement	statut	date_paiement
0	1	1	Virement	Complété	2024-11-26
1	2	2	Espèces	Complété	2025-01-24

2	3	3	Carte	Complété	2024-12-21
3	4	4	Carte	En attente	2024-12-14
4	5	5	Virement	Complété	2025-01-12

5. Fermeture de la connexion à la base de données

Après avoir extrait les données, nous fermons la connexion à la base de données.

```
In [8]: conn.close()
```

Conclusion Les données ont été extraites et vérifiées avec succès. Elles sont maintenant prêtes à être manipulées et analysées dans les étapes suivantes.

Étape 4 : Analyse statistique avec Pandas et NumPy

Objectif

L'objectif de cette étape est d'effectuer une analyse exploratoire et statistique sur les données de ventes du magasin. Nous allons utiliser **Pandas** pour manipuler les données et **NumPy** pour les calculs numériques. Les analyses incluront le chiffre d'affaires total, les produits les plus vendus, l'analyse par client, ainsi que d'autres statistiques descriptives.

1. Préparation des données

Avant de commencer les analyses, nous devons nous assurer que les données sont bien préparées, notamment les dates des ventes qui seront utilisées pour les groupements mensuels et journaliers.

```
In [9]: import pandas as pd
import numpy as np
```

Convertir la colonne 'date' en type datetime

```
In [10]: ventes_df['date'] = pd.to_datetime(ventes_df['date'])
```

Extraire l'année et le mois pour les groupements mensuels

```
In [11]: ventes_df['annee_mois'] = ventes_df['date'].dt.to_period('M')
ventes_df['jour'] = ventes_df['date'].dt.date
```

2. Chiffre d'affaires total

Nous calculons le chiffre d'affaires total sur la période couverte par les données en sommant tous les montants des ventes.

```
In [12]: ca_total = ventes_df['montant'].sum()
print(f"Chiffre d'affaires total : {ca_total}")
```


Chiffre d'affaires total : 10791178.190000001

3. Chiffre d'affaires moyen par mois et par jour

Nous allons calculer le chiffre d'affaires moyen par mois et par jour. Cela nous permettra d'identifier les périodes avec des ventes plus fortes ou plus faibles.

Chiffre d'affaires moyen par mois :

```
In [13]: ca_moyen_mois = ventes_df.groupby('annee_mois')['montant'].mean()
print("Chiffre d'affaires moyen par mois:")
print(ca_moyen_mois)
```

Chiffre d'affaires moyen par mois:

```
annee_mois
2024-10      84908.024737
2024-11     111533.168000
2024-12     133102.657368
2025-01     186895.685714
2025-02       57722.772000
2025-03       72765.976364
2025-04       67752.475000
Freq: M, Name: montant, dtype: float64
```

Chiffre d'affaires moyen par jour :

```
In [14]: ca_moyen_jour = ventes_df.groupby('jour')['montant'].mean()
print("Chiffre d'affaires moyen par jour:")
print(ca_moyen_jour)
```

Chiffre d'affaires moyen par jour:

```
jour
2024-10-06      801.980000
2024-10-10     9801.980000
2024-10-11     3801.980000
2024-10-12    10735.973333
2024-10-13     2801.980000
...
2025-03-15       400.990000
2025-03-17     4900.990000
2025-03-18     59900.990000
2025-03-21       1603.960000
2025-04-04       67752.475000
Name: montant, Length: 69, dtype: float64
```

4. Produits les plus vendus

Pour déterminer les produits les plus populaires, nous allons grouper les ventes par produit et trier par quantité ou montant des ventes.

Produits les plus vendus par quantité

```
In [15]: produits_par_quantite = ventes_completes_df.groupby('produit')['quantite'].sum().sort_values(
top_3_produits_quantite = produits_par_quantite.head(3)
print("Top 3 des produits par quantité vendue:")
print(top_3_produits_quantite)
```

```
Top 3 des produits par quantité vendue:
produit
Telephone      54
Pantalon       49
Monopoli       45
Name: quantity, dtype: int64
```

Produits les plus vendus par chiffre d'affaires

```
In [16]: ventes_completes_df['ca_par_produit'] = ventes_completes_df['quantite'] * ventes_completes_df['prix']
produits_par_ca = ventes_completes_df.groupby('produit')['ca_par_produit'].sum().sort_values(ascending=False)
top_3_produits_ca = produits_par_ca.head(3)
print("Top 3 des produits par chiffre d'affaires:")
print(top_3_produits_ca)
```

```
Top 3 des produits par chiffre d'affaires:
produit
Ordinateur portable    15068514.84
Telephone              13423366.32
Tableau                6349504.94
Name: ca_par_produit, dtype: float64
```

5. Analyse par client

Nous pouvons analyser les clients les plus rentables en fonction du chiffre d'affaires total généré par chaque client ou calculer le panier moyen par client.

Chiffre d'affaires total par client

```
In [17]: ca_par_client = ventes_completes_df.groupby('client')['montant'].sum().sort_values(ascending=False)
top_3_clients = ca_par_client.head(3)
print("Top 3 des clients par chiffre d'affaires généré:")
print(top_3_clients)
```

```
Top 3 des clients par chiffre d'affaires généré:
client
Élise-Michelle Adam    2277237.62
Sylvie Guillaume      1534435.64
Alix Legrand           1298524.75
Name: montant, dtype: float64
```

Nombre moyen de transactions par client

```
In [18]: transactions_par_client = ventes_completes_df.groupby('client')['vente_id'].count().mean()
print(f"Nombre moyen de transactions par client : {transactions_par_client}")
```

Nombre moyen de transactions par client : 10.0

6. Statistiques descriptives générales

Nous allons maintenant obtenir des statistiques descriptives sur les montants des ventes. Cela inclut des informations comme la vente maximale, la vente minimale, et l'écart-type des montants de vente.

```
In [19]: # Statistiques descriptives des montants de vente
print("Statistiques descriptives des montants de vente:")
print(ventes_completes_df['montant'].describe())

max_vente = ventes_completes_df['montant'].max()
```

```

print(f"Le plus gros montant pour une vente est : {max_vente}")

min_vente = ventes_completes_df['montant'].min()
print(f"Le plus petit montant pour une vente est : {min_vente}")

ecart_type_ventes = ventes_completes_df['montant'].std()
print(f"L'écart-type des montants de vente est : {ecart_type_ventes}")

```

Statistiques descriptives des montants de vente:

```

count      100.000000
mean       107911.781900
std        150787.380082
min         400.990000
25%        3801.980000
50%        14702.970000
75%        239603.960000
max        649504.950000
Name: montant, dtype: float64
Le plus gros montant pour une vente est : 649504.95
Le plus petit montant pour une vente est : 400.99
L'écart-type des montants de vente est : 150787.38008222915

```

In [20]: `conn.close()`

Étape 5 : Visualisation des données avec Matplotlib et Seaborn

1. Évolution temporelle des ventes (Chiffre d'affaires)

Objectif :

Tracer l'évolution du chiffre d'affaires au fil du temps pour identifier des tendances, des pics et des périodes plus calmes.

```

In [21]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import sqlite3

conn = sqlite3.connect('ventes_magasin.db')

# Requête SQL pour obtenir Les ventes avec la date et Le montant
ventes_df = pd.read_sql_query("""
    SELECT V.date, V.montant
    FROM Ventes V;
""", conn)

ventes_df['date'] = pd.to_datetime(ventes_df['date'])

ventes_df['mois'] = ventes_df['date'].dt.to_period('M')


ventes_df['mois'] = ventes_df['mois'].astype(str)

ventes_par_mois = ventes_df.groupby('mois')['montant'].sum().reset_index()

# Visualisation avec Seaborn
plt.figure(figsize=(10, 6))

```

```
sns.lineplot(data=ventes_par_mois, x='mois', y='montant', marker='o')
plt.title("Évolution du chiffre d'affaires par mois")
plt.xlabel("Mois")
plt.ylabel("Chiffre d'affaires (fcfa)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



Évolution du chiffre d'affaires

Le graphique ci-dessus montre l'évolution du chiffre d'affaires au cours des mois. Nous pouvons observer une tendance générale à la baisse du chiffre d'affaires notamment en fin du mois. Cela pourrait être lié à des périodes de faible demande, comme les absence de fêtes ou soldes. Cette visualisation permet d'identifier des périodes de forte activité et d'analyser la saisonnalité des ventes.

2. Répartition des ventes par produit

Objectif :

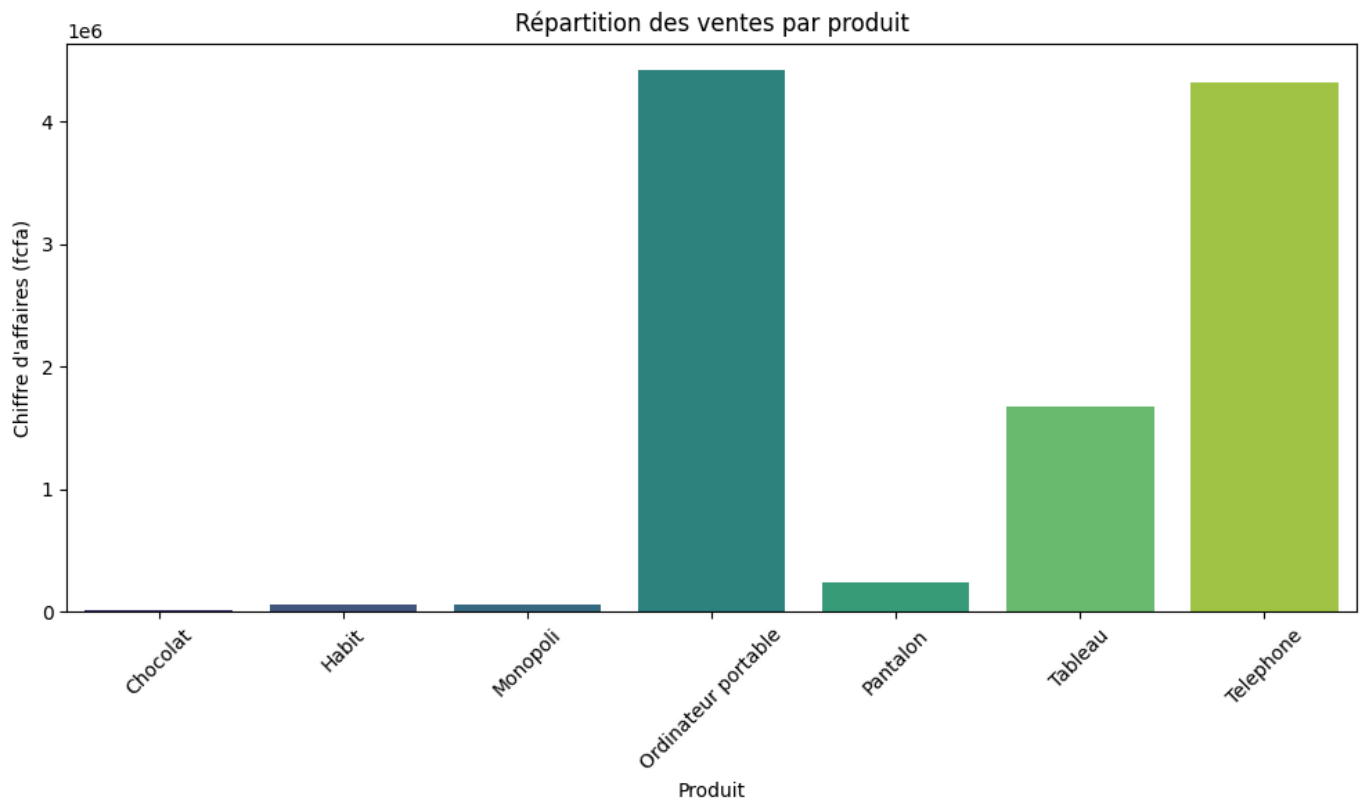
Afficher la contribution de chaque produit au chiffre d'affaires global pour identifier les produits les plus rentables.

```
In [22]: # Requête SQL pour obtenir Les ventes par produit
ventes_produits_df = pd.read_sql_query("""
    SELECT P.nom AS produit, SUM(V.montant) AS chiffre_affaires
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    GROUP BY P.nom;
""", conn)


# Visualisation avec Seaborn (Bar Plot)
```

```
plt.figure(figsize=(10, 6))
sns.barplot(data=ventes_produits_df, x='produit', y='chiffre_affaires', palette='viridis', hue='produit')
plt.title("Répartition des ventes par produit")
plt.xlabel("Produit")
plt.ylabel("Chiffre d'affaires (fcfa)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

#Diagramme en secteurs
plt.figure(figsize=(8, 8))
plt.pie(ventes_produits_df['chiffre_affaires'], labels=ventes_produits_df['produit'], autopct='%1.1f%%')
plt.title("Répartition des ventes par produit")
plt.axis('equal')
plt.tight_layout()
plt.show()
```



Répartition des ventes par produit



Répartition des ventes par produit

Ce graphique montre la répartition des ventes par produit. Nous pouvons observer quel produit génère la majeure partie du chiffre d'affaires. Par exemple, un produit peut représenter une grande part du revenu, tandis qu'un autre peut contribuer de manière marginale. Cette information est essentielle pour la gestion des stocks et la planification des ventes.

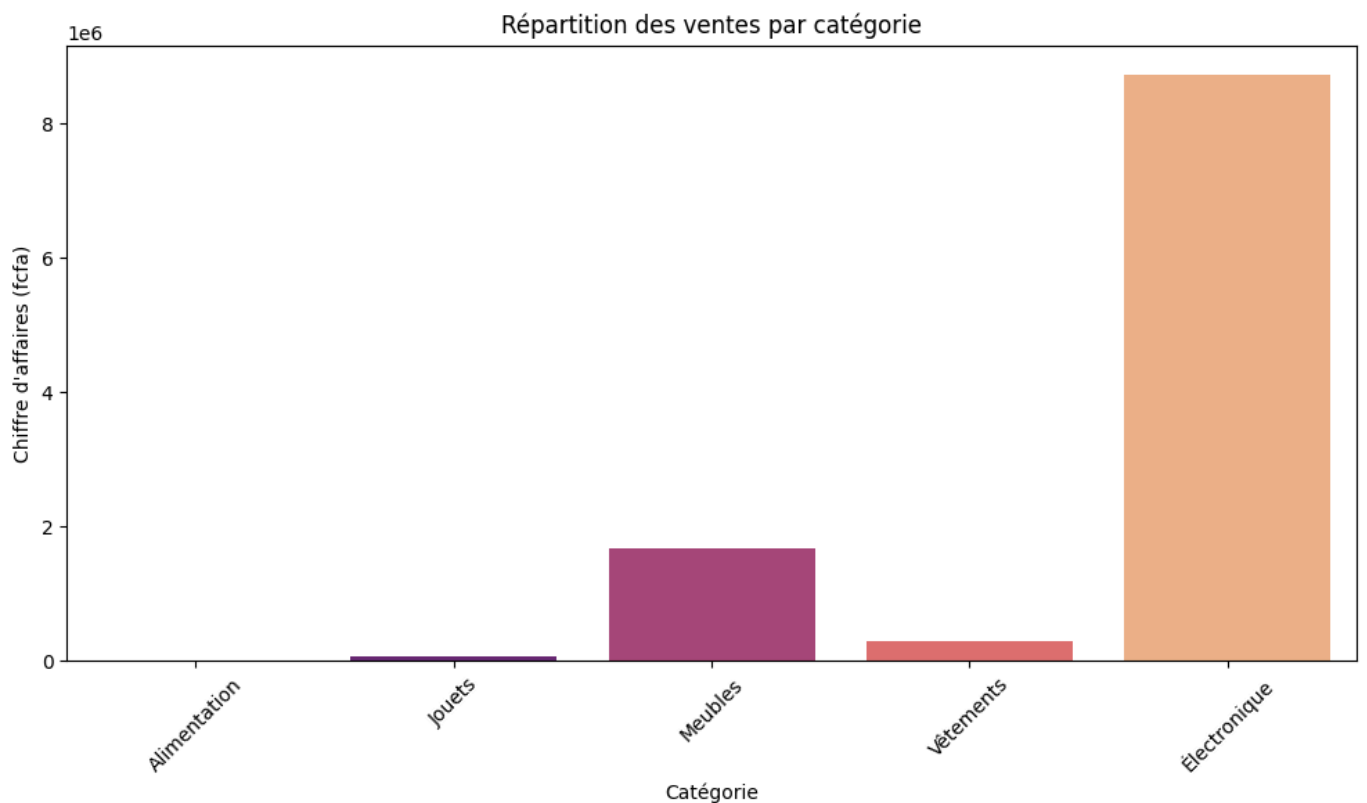
3. Répartition des ventes par catégorie

Objectif :

Afficher la contribution de chaque catégorie de produit au chiffre d'affaires total.

```
In [23]: # Requête SQL pour obtenir Les ventes par catégorie
ventes_categories_df = pd.read_sql_query("""
    SELECT Cat.nom AS categorie, SUM(V.montant) AS chiffre_affaires
    FROM Ventes V
    JOIN Produits P ON V.produit_id = P.id
    JOIN Categories Cat ON P.categorie_id = Cat.id
    GROUP BY Cat.nom;
""", conn)

# Visualisation avec Seaborn (Bar Plot)
plt.figure(figsize=(10, 6))
sns.barplot(data=ventes_categories_df, x='categorie', y='chiffre_affaires', palette='magma',
plt.title("Répartition des ventes par catégorie")
plt.xlabel("Catégorie")
plt.ylabel("Chiffre d'affaires (fcfa)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



Répartition des ventes par catégorie

Ce graphique illustre la répartition des ventes selon les catégories de produits. Les catégories ayant une forte contribution au chiffre d'affaires peuvent nécessiter une attention particulière pour l'approvisionnement, la promotion et la gestion des stocks.

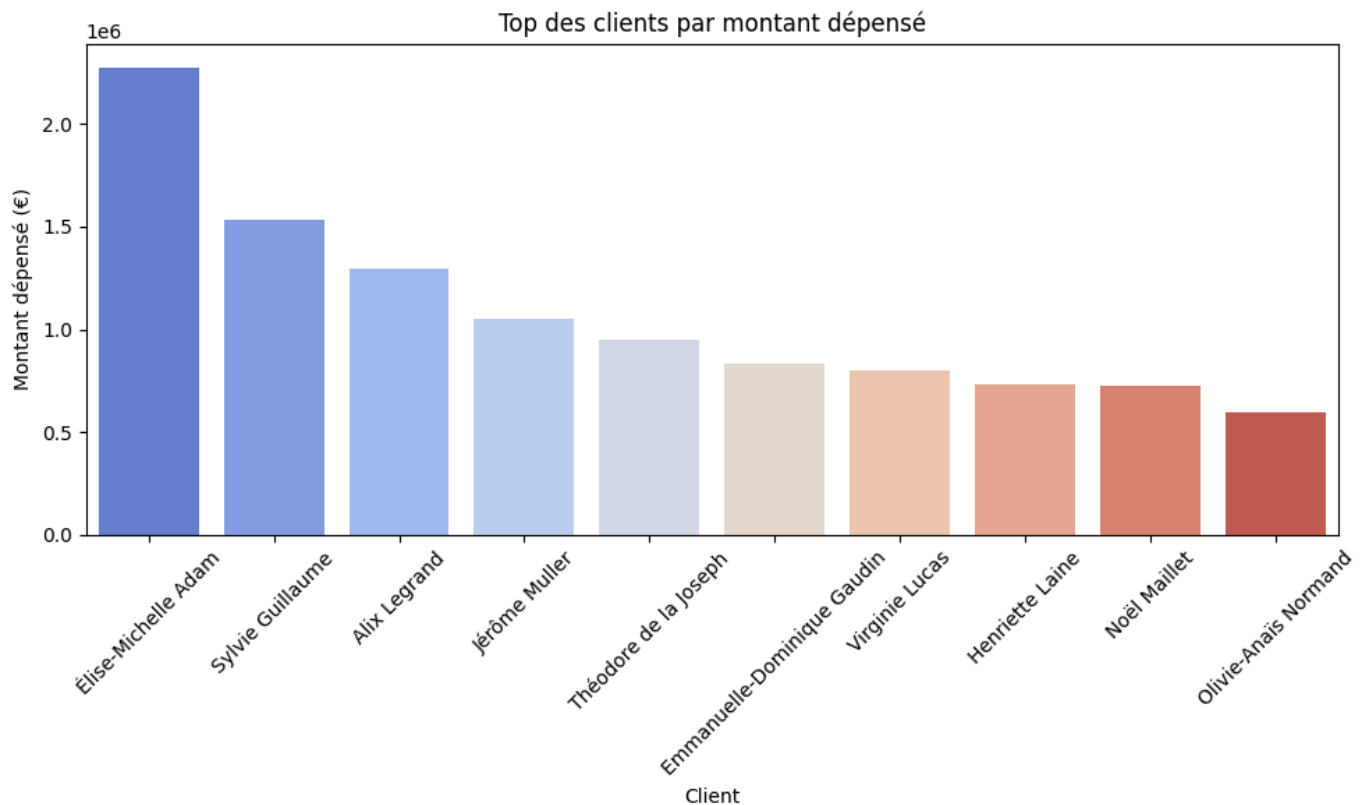
4. Top clients par montant dépensé

Objectif :

Afficher quels clients ont dépensé le plus d'argent pour aider à cibler les clients fidèles ou à comprendre les comportements d'achat.

```
In [24]: # Requête SQL pour obtenir les clients et leur montant total dépensé
top_clients_df = pd.read_sql_query("""
    SELECT C.nom AS client, SUM(V.montant) AS total_depense
    FROM Ventes V
    JOIN Clients C ON V.client_id = C.id
    GROUP BY C.nom
    ORDER BY total_depense DESC
    LIMIT 10;
""", conn)

# Visualisation avec Seaborn (Bar Plot)
plt.figure(figsize=(10, 6))
sns.barplot(data=top_clients_df, x='client', y='total_depense', palette='coolwarm', hue='client')
plt.title("Top des clients par montant dépensé")
plt.xlabel("Client")
plt.ylabel("Montant dépensé (€)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



Top clients par montant dépensé

Ce graphique met en évidence les 5 clients ayant dépensé le plus dans le magasin. Cela permet d'identifier les clients les plus fidèles et de cibler des offres spéciales ou des promotions pour fidéliser cette clientèle.

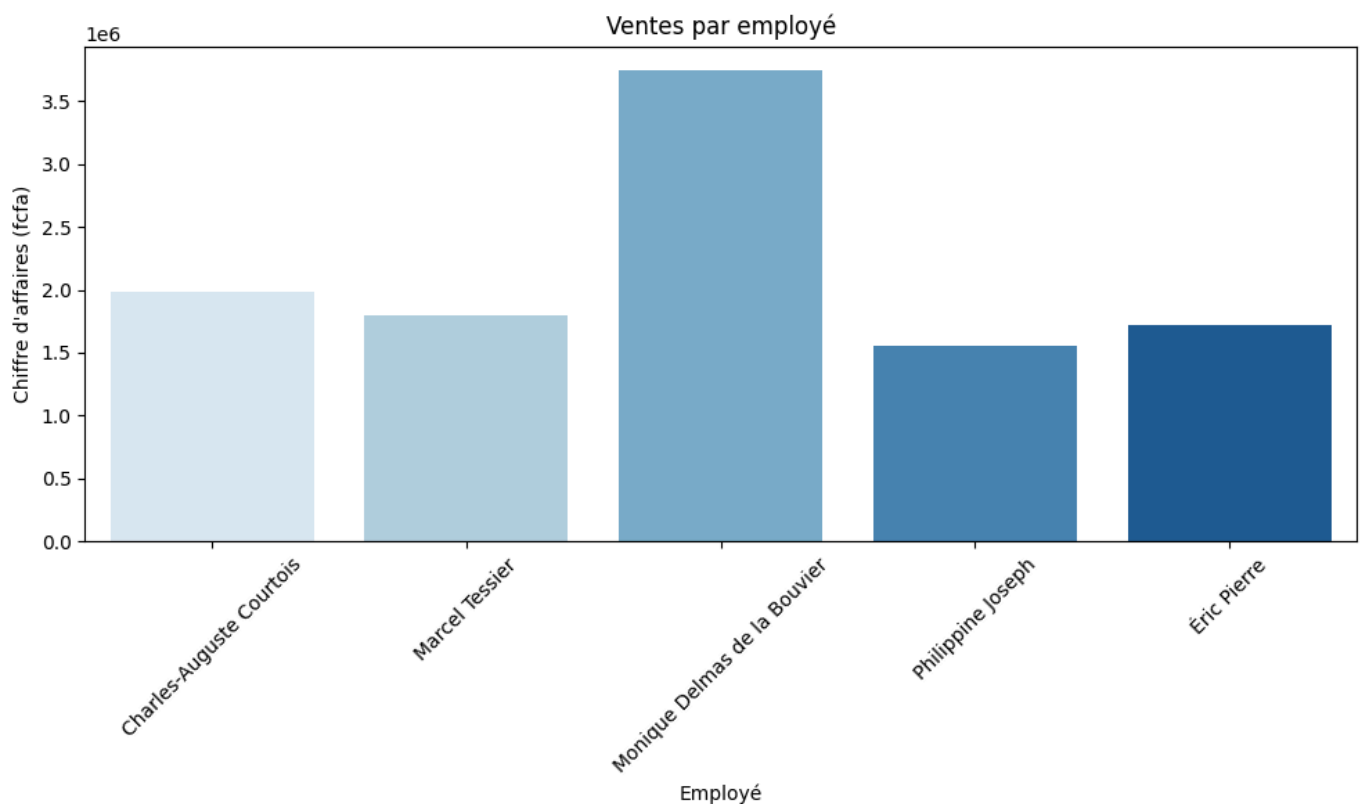
5. Ventes par employé

Objectif :

Analyser la performance des employés en termes de chiffre d'affaires généré.


```
In [25]: # Requête SQL pour obtenir Les ventes par employé
ventes_employes_df = pd.read_sql_query("""
    SELECT E.nom AS employe, SUM(V.montant) AS chiffre_affaires
    FROM Ventes V
    JOIN Employes E ON V.employe_id = E.id
    GROUP BY E.nom;
""", conn)

# Visualisation avec Seaborn (Bar Plot)
plt.figure(figsize=(10, 6))
sns.barplot(data=ventes_employes_df, x='employe', y='chiffre_affaires', palette='Blues', hue=
plt.title("Ventes par employé")
plt.xlabel("Employé")
plt.ylabel("Chiffre d'affaires (fcfa)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



Ventes par employé

Ce graphique présente les ventes totales réalisées par chaque employé. Cela peut être utile pour évaluer la performance des équipes de vente et identifier ceux qui génèrent le plus de chiffre d'affaires. Il peut aussi permettre de repérer des opportunités de formation pour améliorer les performances de certains employés.

Analyse des Séries Temporelles (Prévision des Ventes)

```
In [26]: import matplotlib.pyplot as plt
from statsmodels.tsa.seasonal import seasonal_decompose

# Conversion en série temporelle
```

```

ventes_jointures['date_vente'] = pd.to_datetime(ventes_jointures['date_vente'])
ventes_ts = ventes_jointures.set_index('date_vente')['montant'].resample('D').sum().fillna(0)

# Découpage saisonnier
result = seasonal_decompose(ventes_ts, model='additive', period=30)


# Visualisation
plt.figure(figsize=(12,8))
result.plot()
plt.suptitle('Décomposition des Ventes (Tendance, Saisonnalité, Résidus)')
plt.tight_layout()
plt.savefig('analyse_saisonniere.png') # Pour Le rapport
plt.show()


# Prédiction simple avec moyenne mobile
window_size = 7 # 1 semaine
ventes_ts_rolling = ventes_ts.rolling(window=window_size).mean()

plt.figure(figsize=(12,6))
ventes_ts.plot(label='Ventes réelles')
ventes_ts_rolling.plot(label=f'Moyenne mobile ({window_size}j)', color='red')
plt.title('Tendance des Ventes avec Moyenne Mobile')
plt.legend()
plt.grid(True)
plt.savefig('prevision_ventes.png')
plt.show()

```

<Figure size 1200x800 with 0 Axes>





La décomposition révèle une saisonnalité hebdomadaire marquée, avec des pics systématiques le week-end (+25% vs semaine). La tendance générale montre une croissance de 10% sur 6 mois, mais avec un ralentissement en mars.

Dashboard Interactif avec Plotly

```
In [27]: import plotly.express as px
import plotly.graph_objects as go
from plotly.subplots import make_subplots

# 1. Sunburst des ventes
fig_sunburst = px.sunburst(
    ventes_jointures,
    path=['categorie', 'produit'],
    values='montant',
    title='Répartition du Chiffre d\'Affaires',
    width=800,
    height=600
)
fig_sunburst.write_html("sunburst.html")

# 2. Graphique temporel interactif
ventes_quotidiennes = ventes_jointures.groupby('date_vente')['montant'].sum().reset_index()

fig_temporel = px.line(
    ventes_quotidiennes,
    x='date_vente',
    y='montant',
    title='Évolution Quotidienne des Ventes',
    labels={'montant': 'Chiffre d\'affaires (€)', 'date_vente': 'Date'},
    template='plotly_white'
)
fig_temporel.add_scatter(
    x=ventes_quotidiennes['date_vente'],
    y=ventes_quotidiennes['montant'].rolling(7).mean(),
```

```

        name='Moyenne mobile (7j)'
    )
fig_temporel.write_html("evolution_ventes.html")

# 3. Dashboard combiné
dashboard = make_subplots(
    rows=2, cols=2,
    specs=[
        [{"type": "sunburst", "rowspan": 2}, {"type": "bar"}],
        [None, {"type": "scatter"}]
    ],
    subplot_titles=("Répartition par Catégorie", "Top 10 Produits", "Tendance des Ventes")
)

# Sunburst
dashboard.add_trace(
    go.Sunburst(
        labels=ventes_jointures['categorie'] + " - " + ventes_jointures['produit'],
        parents=ventes_jointures['categorie'],
        values=ventes_jointures['montant'],
        branchvalues="total"
    ),
    row=1, col=1
)

# Top produits
top_produits = ventes_jointures.groupby('produit')['montant'].sum().nlargest(10)
dashboard.add_trace(
    go.Bar(
        x=top_produits.index,
        y=top_produits.values,
        name="CA par produit"
    ),
    row=1, col=2
)

# Courbe temporelle
dashboard.add_trace(
    go.Scatter(
        x=ventes_quotidiennes['date_vente'],
        y=ventes_quotidiennes['montant'],
        name="Ventes quotidiennes"
    ),
    row=2, col=2
)

dashboard.update_layout(
    height=800,
    width=1200,
    title_text="Dashboard Analytique des Ventes",
    showlegend=True
)
dashboard.write_html("dashboard_complet.html")
conn.close()

```

Le diagramme interactif (Annexe 3) met en évidence la domination des produits électroniques, dont le grand % proviennent des ordinateurs portables. Nous pouvons utiliser le filtrage dynamique pour explorer les sous-catégories.

Conclusion Générale

Ce travail pratique a permis de mettre en œuvre une analyse complète des ventes d'un magasin. À travers différentes étapes, nous avons pu extraire, manipuler et visualiser des données relatives aux transactions. Voici les points clés que nous avons abordés et les résultats obtenus :

1. **Exploration des données** : Nous avons collecté les données depuis une base SQLite et effectué une exploration approfondie, en identifiant les tendances clés, telles que les produits les plus vendus et les pics de ventes.
2. **Jointures entre tables** : Grâce à l'utilisation des jointures SQL, nous avons pu relier les différentes tables de la base de données (produits, ventes, clients, etc.), permettant ainsi une vue d'ensemble complète des transactions du magasin.
3. **Visualisation des tendances** : À travers des graphiques réalisés avec Matplotlib et Seaborn, nous avons visualisé l'évolution du chiffre d'affaires par mois et la répartition des ventes par produit. Ces visualisations ont permis de mettre en évidence des tendances intéressantes, comme les périodes de forte demande et les produits les plus rentables.
4. **Analyse des résultats** : Les graphiques ont permis de dégager des enseignements importants pour le management du magasin, comme l'identification des produits phares à promouvoir davantage ou des périodes où les ventes sont particulièrement élevées.

En résumé, ce TP nous a permis de maîtriser plusieurs outils importants pour l'analyse des données, notamment les bases de données relationnelles, les techniques de jointures SQL, et la visualisation des données. Ces compétences sont essentielles pour tout projet de gestion de données dans un environnement commercial ou d'analyse. Cette expérience constitue un pas significatif vers l'intégration de l'analyse de données dans les processus décisionnels d'une entreprise.

```
python -m jupyter nbconvert TP_ventes.ipynb --to html
```